

MLP

2026 청소년 수리 인공지능 아카데미

2026-05-16

Presenter: Jaehyung Lim

Postech Graduate School of AI


jaehyunlim@postech.ac.kr

복습) Regression

- 입력 x 에 대한 결과 y 의 관계를 모델링하는 것
- y : 연속적인 값
- Ex) x : 발사이즈, y : 키
- Ex) x : 발사이즈, y : 남성(혹은 여성) 일 확률


복습) Linear Regression

- 입력 x (발사이즈)에 대한 결과 y (키)의 관계를 모델링하는 것




복습) Linear Regression

- 입력 x (발사이즈)에 대한 결과 y (키)의 선형 관계를 모델링하는 것
= 데이터를 가장 잘 표현하는 직선 찾기




복습) Linear Regression

- 데이터를 가장 잘 표현하는 직선 찾기




복습) Linear Regression

- 데이터를 가장 잘 표현하는 직선 찾기



복습) Linear Regression

- Least/Mean Square Error



복습) Linear Regression


- 데이터를 가장 잘 표현하는 직선 찾기

$$L = \sum_{i=1}^n (y_i - (ax_i + b))^2 = g(a, b)$$

$g(a, b)$ 최소가 되는 경우


복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때




복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때




복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때



복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때



복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때

$$\hat{y} = \frac{1}{1 + e^{-(ax_i + b)}}$$

복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때

$$\hat{y} = \frac{1}{1 + e^{-(ax_i+b)}}$$


$$L = \sum_{i=1}^n \left(y - \frac{1}{1+e^{-(ax_i+b)}} \right)^2$$

or

$$L = \sum_{i=1}^n \ln\left(\frac{1}{1+e^{-(ax_i+b)}}\right) + \ln\left(1 - \frac{1}{1+e^{-(ax_i+b)}}\right)$$

복습) Logistic Regression

- 만약 관계를 구하려는 데이터의 정답이 두가지 종류로 구분될 때




복습) Classification (분류)

- 입력 x 에 대해서 미리 정해진 종류(y)로 구분하는 것
- $y \in \{0, 1, \dots\}$
- EX) 이진분류 (O/X, 남성/여성, -1/1, 0/1)

SVM (분류)


17

- 입력 x 에 대해서 미리 정해진 종류(y)로 구분하는 것




SVM (분류)

- 입력 x 에 대해서 margin이 최대인 직선 찾기



SVM (분류)

- 입력 x 에 대해서 margin이 최대인 직선 찾기



SVM (분류)


- 입력 x 에 대해서 margin이 최대인 직선 찾기

margin 최대화

$$\max_{a,b} \frac{2}{\sqrt{a^2 + b^2}}$$

$$= \min_{a,b} (a^2 + b^2)$$

우유



밀가루


SVM (분류)

- 입력 x 에 대해서 margin이 최대인 직선 찾기

margin 최대화


$$= \min_{a,b} (a^2 + b^2)$$

Where $|ax_1 + bx_2 + c| \geq 1$




단순한 결정 경계의 한계

- 선형 회귀, SVM
- 잘못 분류하는 경우가 많아짐




단순한 결정 경계의 한계

- 비선형 결정 경계 필요함
- => MLP (Multi-Layer Perceptron)




신경세포, 퍼셉트론

- Neuron




신경세포



퍼셉트론



- Perceptron: Single-Layer Neural Network
 - 입력: $\mathbf{x} = [x_1, x_2, \dots, x_d]$
 - 결과: y
 - 모델 가중치 (파라미터) $\mathbf{w} = [w_1, w_2, \dots, w_d]$
 - f : 활성화 함수

$$y = f(z) = f\left(\sum_i w_i x_i + b\right)$$





단일 뉴런으로 표현 가능한 결정 경계

-



뉴런들의 결합?

•




?

활성화 함수 (비선형 함수)

•


$$y = f(z) = \sum_i w_i x_i + b \rightarrow \underline{\text{단순 직선}}$$

$$y = f(z) = f(\sum_i w_i x_i + b) \rightarrow \underline{\text{곡선 형태}}$$




활성화 함수 (비선형 함수)

- 활성화 함수를 추가하니 아래와 같은 보다 복잡한 결정 경계를 얻을 수 있음




Multi-Layer Perceptron (MLP)

- 퍼셉트론과 활성화 함수를 넓고 깊게 연결하면 매우 복잡한 결정 경계 표현 가능




Multi-Layer Perceptron (MLP)

-




Multi-Layer Perceptron (MLP)




Multi-Layer Perceptron (MLP)

33




MLP 학습

- 신경망을 학습한다는 것?




MLP 학습

35



$$x_m \rightarrow y_m = 0$$

$$x_c \rightarrow y_c = 1$$



MLP 학습

36

- 정답이 0일 때?

$$x_m \rightarrow y = 0$$

$$\hat{y}_m \leftrightarrow y$$

$$\hat{y}_m \leftrightarrow 0$$

둘이 가까운 (비슷한?) 값이면 좋겠다!

$(\hat{y}_m - 0)^2$ 을 최소값으로 만드는 경우!!

MLP 학습

37

- 정답이 1일 때?

$$x_m \rightarrow y = 1$$

$$\hat{y}_m \leftrightarrow y$$

$$\hat{y}_m \leftrightarrow 1$$

둘이 가까운 (비슷한?) 값이면 좋겠다!

$(\hat{y}_m - 1)^2$ 을 최소값으로 만드는 경우!!

MLP 학습

-

정답 0 $(\hat{y}_m - 0)^2$ 최소화

정답 1 $(\hat{y}_c - 1)^2$ 최소화

$f = \sum_i (\hat{y}_i - y_i)^2$ 최소화  미분

$x_m \rightarrow y_m = 0$

$x_c \rightarrow y_c = 1$

-

$$f = \sum_i (\hat{y}_i - y_i)^2 \text{ 최소화}$$

$$f: f(w_1, w_2, w_3, \dots, b_1, b_2, \dots)$$

$$\frac{\partial f}{\partial w_1} = \frac{\partial f}{\partial w_2} = \dots = \frac{\partial f}{\partial b_n} = 0$$

=> 연립 방정식의 해 항상 구할 수 있나?

미분 기초

- 직선의 기울기


- $\frac{f(a+h)-f(a)}{a+h-a}$

- 기울기 >0 , <0 , $=0$

미분 기초



- 미분의 정의

$$\frac{\Delta y}{\Delta x} = \frac{f(a + \Delta x) - f(a)}{\Delta x}$$



미분 기초

- 미분의 활용 (함수의 최대/소)




경사하강법

43

•

$$w = w - \eta \cdot f'$$




η : 적당할 때

경사하강법

44

•


$$w = w - \eta \cdot f'$$



η : 과도하게 클 때


MLP 다중 분류

- 분류 클래스(=종류)가 여러 개라면?
- 기존에 사용한 방법 처럼 y 값을 0 ~ 9 사이의 값으로 출력하는게 좋을지??




MLP 다중 분류

46




MLP 다중 분류

47




MLP 다중 분류

- 값 정규화




Softmax

- 아이디어: 어떻게 일반 실수값들을 상대적으로 잘 비교하게끔 표현하지?
- 실수 -> 확률 범위로 표현하면 좋을 듯
- 단순한 아이디어: 합을 분모?



Softmax


- Exp 함수를 사용해서 음수 -> 양수
- Exp 함수: 작은 값의 차이도 크게 바꿔줌
- Softmax: sigmoid의 일반화 버전



Softmax


51

- Softmax -> 최대 값을 결과로 가지는 max 함수를 "soften"




Softmax

- 실수 -> 확률 범위




Softmax

- 실수 -> 확률 범위



다중분류 MLP 학습

- 기존 이중분류 처럼 두 값의 차이를 줄이는 방향으로 학습?
- 밝혀진 연구에 의하면 해당 학습 방법은 softmax를 사용했을 때 좋은 결과를 보여주지 못한다고 함



In particular, squared error is a poor loss function for softmax units and can fail to train the model to change its output, even when the model makes highly confident incorrect predictions (Bridle, 1990).

다중분류 MLP 학습

- 실수 -> 확률
- 확률 기반의 모델링
- 사건 (클래스의) 종류가 3개 이상이므로 multinomial 분포 사용해서 모델링

N번의 독립 시행에서 각 시행의 사건이 세종류 a,b,c, p_a, p_b, p_c 확률 가질 때
각 x, y, z 번 일어날 확률 ($x + y + z = N$, $p_a + p_b + p_c = 1$)

$$P(x, y, z | p_a, p_b, p_c) = \frac{(x + y + z)!}{x! y! z!} \cdot p_a^x \cdot p_b^y \cdot p_c^z$$

다중분류 MLP 학습


- 아이디어
- Multinomial에서 $x + y + z = 1$ 이니까, 해당하는 클래스의 확률 값을 (softmax의 결과 값)을 올리는 방향으로 학습할 수 있음

$$P(x, y, z | p_a, p_b, p_c) = \frac{(x + y + z)!}{x! y! z!} \cdot p_a^x \cdot p_b^y \cdot p_c^z$$

- x, y, z 셋 중에 하나만 1, 나머지는 0 ($x+y+z=1$)
- 확률은 각 class의 예측값
- Log?
- $\sum y_i \cdot \log \hat{y}_i$ 최대화
- $-\sum y_i \cdot \log \hat{y}_i$ 최소화

다중분류 MLP 학습


- 최종 학습 수식



$$\mathcal{L} = \sum_{d \in D} \sum_{i \in C} -y_i^d \cdot \log \hat{y}_i^d$$


MNIST

- 손글씨 데이터셋
- Modified National Institute of Standards and Technology database
- 인공지능 모델의 학습, 평가에 사용
 - 학습: 60,000
 - 평가: 10,000



MNIST

59



MNIST + MLP + 다중분류

